

Guiding-DIP-Early-Stopping-with-DDPM-inspired-Supervision

Introduction

本報告涵蓋基於 DIP 基礎上增加噪音方法的實作，藉以引導 DIP 學習噪音的特徵。前半部分會分析原始 DIP 與加上噪音的問題，後半部分則解決問題與最終結果。

Experiment Setup

Dataset: Mammals Image Classification Dataset (45 Animals) on Kaggle

Model

Architecture: 類似 Unet 但不是標準 Unet 的 Hourglass

Framework: PyTorch

Optimizer: Adam

Loss: Mean Squared Error (MSE)

Training Procedure

DIP only

DIP with given noisy image

Adding Noise Method

使用的是 DDPM 的前向過程。在前向過程中，從正態高斯分佈中取樣的 Noise 會逐漸添加到圖像樣本中。給定圖像 x_0 和 Noise ϵ ，其中 $\epsilon \sim N(\mu, I)$ ，在包含 T 個時間步的 Markov chain，從 $t=0$ 到 $t=T-1$ ，前向過程 q 可以被定義為：

$$q(x_{t+1}|x_t) = N(x_{t+1}; \sqrt{1 - \beta_{t+1}}x_t, \beta_{t+1}I)$$

其中 β 由原始 DDPM 論文的 beta-min 和 beta-max 定義的值，定義方式如下：


線性方法： $\beta_t = \beta_{\min} + t \cdot \frac{\beta_{\max} - \beta_{\min}}{T}$

餘弦方法： $\beta_t = \beta_{\min} + 0.5(\beta_{\max} - \beta_{\min})(1 - \cos(\frac{t}{T}\pi))$


本實驗過程經過測試，最終採用的方法為線性。

Implementation Process (I)

先透過 DDPM 前向過程，產生數張 noisy 圖片， $t=0$ 為無 noisy。




根據作業要求，由 noise 最嚴重的圖片開始，依序放入 DIP 過程。因此將 noisy 圖片序列翻轉，以及移除無 noisy 圖片。總共 7 張圖片




每張圖片跑 400 次迭代，總共 2800 次。

原始 DIP 在整個過程只跑第 7 張（Noise 最少的圖片），結果如下。

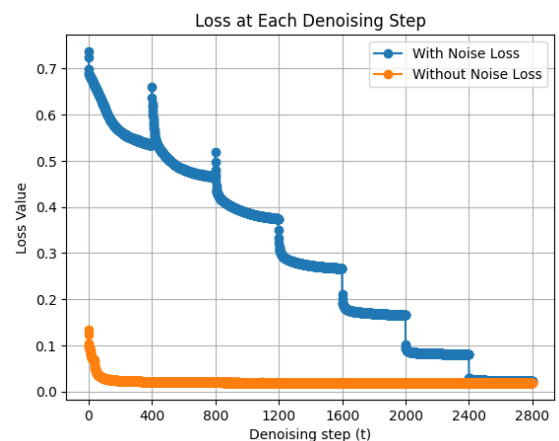


原始 DIP 在不同 400 次迭代的過程跑不同 noisy 程度的圖片，由最嚴重到最輕，結果如下。

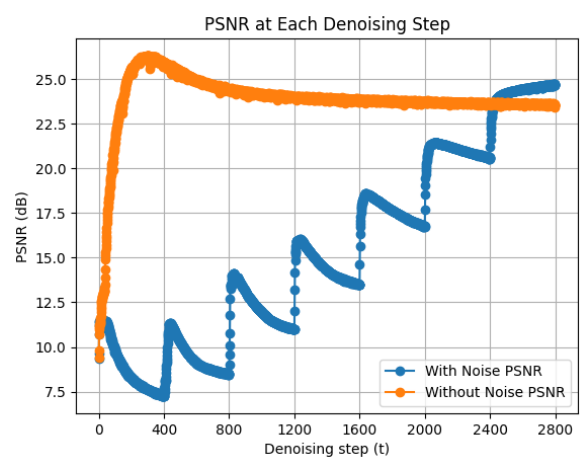


Analysis of Implementation Process (I)


右圖為兩者 **Loss** 的比較圖，計算 **Loss** 方式是產生的圖片比對原圖（無 noise）。可看出有 **Noise** 的過程在每次換圖片時，loss 會回到高點。



右圖為兩者的 **PSNR** 比較圖。**PSNR** 是用來評估圖像訊號的差異，因此可用來檢視噪音是否被正確消除。以每 400 迭代為一個區間，可發現當經過一定的 **t**，會有個早停點，之後 **PSNR** 開始下降，出現過擬和（**Overfitting**），表示噪音特徵被過度重視。



右圖為兩者的 **SSIM** 比較圖。**SSIM** 是用來評估人眼對圖像感知的差異，包含亮度、對比度和結構。以每 400 迭代為一個區間，可發現當經過一定的 **t**，**SSIM** 開始下降，一樣也是出現過擬和（**Overfitting**）。



根據分析內容，為了解決過擬和與效果不如原始 **DIP**。於是接續 **Implementation Process (II)**。

Implementation Process (I)